

STUDYWAVE · TEAM IMPLEMENTATION SPEC



PDF / → AgentState → + + Streamlit / Obsidian .md

|    |     |                          | Graph Node      |
|----|-----|--------------------------|-----------------|
| A  | · · | graph/, schemas/state.py | route, verify   |
| B  | · · | workers/parser/, store/  | parse, retrieve |
| C  | · · | workers/analysis/        | analyze         |
| D  | ·   | workers/formatter/       | format          |
| UI | · · | app.py, ui/              | run_pipeline    |

## 1. ■ ■ ■ ■ ■ ■ ■ ■

■ ■■■ StudyWave ■■■■ ■■ ■■■■ ■■■■, ■■■■ ■■■■ ■■■■■■ ■■ ■■■ ■■■■, ■■■■ ■■■■ ■ ■■■. ■■■ ■■■■■■ ■■■■. ■■ ■■■■ ■ ■■■■ ■■■ .py ■ ■■■. ■■ ■■■■ ■■ key ■ ■■■ ■■ ■■■■ ■■■■ ■■■■, ■■■ ■■■ ■■ ■■ ■■■ ■■.

## 2. ■ ■ ■ ■ ■

Streamlit PDF, LangGraph Worker, Obsidian .md 3~5.

- **■■■**: PDF■ / ■■■■ / ■■. ■■ ■■■■ graph/router.py ■ detect\_route.
- **■■■**: ■ ■■■■ schemas/state.py ■ AgentState ■■■■.
- **■■■**: ■■■■ Chunk ■ store/vector\_store.py (PostgreSQL + pgvector).
- **■■■**: C ■ ■■ ■■■■ ■■■■ D ■ ■■■■ ■■■■ ■■■■.
- **■■■**: A ■■■:■■■■.route ■■■■ ■■■■ ■■■■ ■ UI ■■■■.

### 3. ■ ■ ■ ■ ■ (■■■)

```
from random import randint, choice
```

```
app.py
  ■■ ui/app.py
      ■■ ■■■■ ■■■■ FileInfo ■■■■ ■■
      ■■ graph/supervisor.py → run_pipeline(files)
```

```
graph/supervisor.py      (StateGraph.compile → invoke)
1) graph/router.py       route_input_node
2) workers/parser/nodes.py  parse_files_node
   ■■ workers/parser/pdf_parser.py
   ■■ workers/parser/code_parser.py
   ■■ workers/parser/preprocess.py
   ■■ store/vector_store.py      upsert_chunks
3) workers/parser/nodes.py  retrieve_chunks_node
   ■■ store/vector_store.py      retrieve_vector_documents
4) workers/analysis/nodes.py analyze_node
   ■■ workers/analysis/prompts.py
   ■■ workers/analysis/concept.py
   ■■ workers/analysis/code_flow.py
   ■■ workers/analysis/cross_reference.py
   ■■ workers/analysis/flow_diagrams.py
   ■■ workers/analysis/reference_tables.py
   ■■ workers/analysis/practice_notes.py
5) workers/formatter/nodes.py format_node
   ■■ workers/formatter/quiz.py
   ■■ workers/formatter/markdown.py
6) graph/verify.py         verify_node
```

```
ui/tabs.py ← AgentState
[ [ ] [ ] [ ] ]
+ final markdown
```

1. Worker. U.S. Bureau of Labor Statistics.

#### 4. ■ ■ ■ ■ ■ ■ ■ ■

## 4.1 AgentState ■ ■ ■ ■ ■

graph/supervisor.py ■ Worker ■■■ ■■■ ■■■■ ■■■■ ■■■■. ■ Node ■ state ■ ■■■ ■■■■ ■■■ key ■ dict ■ ■■■■, LangGraph ■ ■ key ■ AgentState ■ ■■■■. ■■■■ B ■ ■■■■ ■■■■ C ■ mocks/data.py ■ retrieved\_chunks ■ ■■■■ ■■■■ ■■■■ ■■■■.

| Node     | ■■■                        | ■■■■ ■■■■ key                                                                 |
|----------|----------------------------|-------------------------------------------------------------------------------|
| route    | graph/router.py            | route, status                                                                 |
| parse    | workers/parser/nodes.py    | files, parsed_chunks, status                                                  |
| retrieve | workers/parser/nodes.py    | retrieved_chunks, status                                                      |
| analyze  | workers/analysis/nodes.py  | concepts, code_units, flows, tables, cross_references, practice_notes, status |
| format   | workers/formatter/nodes.py | quiz_items, final_markdown, status                                            |
| verify   | graph/verify.py            | verification, quiz_items, status, errors                                      |

## 4.2 Mock ■■■ ■■■ ■■■■ ■■■■

graph/supervisor.py ■ USE MOCK = True ■■■ B/C/D ■■■ ■■■■ ■■■■ python run\_graph.py ■ ■■■■ ■■■■ ■■■■. ■■■■ Node ■ ■■■ ■■■■ ■■■ ■ USE MOCK = False ■ ■■■■ supervisor ■ ■■■ ■■■■ import ■■■. ■■■ ■■■■ ■■■■ ■■■■ ■■■■.

## 4.3 ■■■ ■■■ ■■■■

| ■■■                   | ■■■ ■■■             | ■■■                                                                                           |
|-----------------------|---------------------|-----------------------------------------------------------------------------------------------|
| schemas/state.py      | A ■■■, ■■■ import   | AgentState TypedDict. ■■■ ■■■.■■■■ ■■■ ■■■.                                                   |
| schemas/files.py      | B ■■■, C·D·A ■■■    | FileInfo, Chunk, RetrievedChunk. chunk_id ■■■ ■■■.                                            |
| schemas/analysis.py   | C ■■■, D·UI ■■■     | ConceptItem, CodeAnalysisItem, FlowDiagram, ReferenceTable, CrossReferenceItem, PracticeNote. |
| schemas/quiz.py       | D ■■■, A·UI ■■■     | QuizItem. answer ■ ■■■ ■■■■ ■■■■.                                                             |
| schemas/errors.py     | A ■■■, UI ■■■       | NodeError, VerificationReport.                                                                |
| config.py             | ■■■                 | GEMINI_API_KEY, LLM_PROVIDER, VECTOR_BACKEND, TOP_K.                                          |
| store/vector_store.py | B ■■■, retrieve ■■■ | initialize / upsert / retrieve. ■■■■ ■■■■ ■■■■.                                               |
| mocks/data.py         | ■■■ ■■■             | ■■■■ ■■■ JSON ■■■. ■■■ ■■■■ ■■■ ■■■.                                                          |

## 5. ■■■ ■■■ (■■■)

- ■■■ None ■■■ key ■■■ ■■■ [] ■ ■■■■. ■■■■ ■■■■ None.
- ■■■■ 1■■■. PDF ■ page\_number, ■■■■ start\_line / end\_line.
- chunk\_id = {document\_id}:chunk:{index:04d}, document\_id = {request\_id}:{■■■■}.
- .■■■ ■■■■ source\_chunk\_ids ■ ■■■■. ■■■ ■■■ ■■■■ ■■■ ■■■■.
- API ■■■ .env ■ GEMINI\_API\_KEY ■ ■■■■. ■■■■ ■■■■ git ■ ■■■ ■■■■ ■■■■.
- ■■■■ ■■■■ ■■■■ ■■■ ■■■■ ■■■■ ■■■■ ■■■■.
- : ■■■■ ■■■■ pip install -r requirements.txt.



## 7. A ■■■ ■■■■ — ■■■ / ■■■■ / ■■■

A ■ Worker ■ ■■■■■ ■■, ■■ ■■■■ ■■ ■■■■, ■■ ■■■■ ■■■■ ■■ ■■■■ ■■■■ ■■■■. LLM ■■■ ■■■ ■■■ ■■■■. ■■■ ■■ ■■■ ■■■■■■.

### 7.1 ■■■ ■■■

| ■■■                 | ■■■ ■■                  | A ■ ■ ■                                                 |
|---------------------|-------------------------|---------------------------------------------------------|
| graph/supervisor.py | ■■■ Edge + Mock Node ■■ | USE MOCK=False ■■ ■■. retry ■ add_conditional_edges ■■. |
| graph/router.py     | detect_route ■■■        | ■■■.source_type ■■ ■■. LLM ■■■■ ■■ ■■.                  |
| graph/verify.py     | ■■■ ■■■■■               | citation / quiz / route ■■■ verify_node ■■.             |
| schemas/state.py    | ■■■ ■■ ■■               | ■■■ ■■ ■■. ■■■ ■■/■■■ ■■.                               |
| schemas/errors.py   | ■■■ ■■                  | error_code ■■■ ■■ ■■ (PARSE_FAIL, EMPTY_SECTION ■).     |
| run_graph.py        | ■■■                     | ■■■ ■■ ■■ ■■ ■ ■■■ ■■■ ■■.                              |

### 7.2 ■■■ ■■■

- python run\_graph.py ■ ■■■ route / status / chunks / quiz / passed ■ ■■■■■ ■■■■. (langgraph ■■ ■■)
- graph/router.py ■ detect\_route ■ PDF■, ■■■■, ■ ■ ■■■■■ ■■■ ■■■ ■■.
- graph/verify.py ■ collect\_known\_chunk\_ids ■■ ■■■■. parsed\_chunks ■ retrieved\_chunks ■ chunk\_id ■■■■ ■■■■.
- validate\_citations: C·D ■■■■ source\_chunk\_ids ■ ■ ■■ ■■ ■■■■ ■■. ■■ id ■ issues ■■■■ ■■■■.
- validate\_quiz\_items: quiz\_type ■ mcq ■■ answer ■ options ■ ■■■■ ■■. ■■■■ ■■■■ dropped\_quiz\_ids ■ ■■■■ ■■■■.
- validate\_route\_outputs: pdf\_only ■■ concepts ■ [] ■■ ■■, code\_only ■■ code\_units ■ [] ■■ ■■, both ■■ cross\_references ■ [] ■■ ■■.
- verify\_node ■■ ■ ■■■■■ ■■ VerificationReport ■ ■■■■ status ■ completed ■■ failed ■ ■■.
- config.NODE\_FAILURE\_POLICY ■ retry ■■ retryable ■■■■ ■■■■ supervisor ■ add\_conditional\_edges ■ ■■■■. ■■■■ partial ■■ ■■ ■■■ UI ■■■■ ■■.

### 7.3 ■■■ ■■■

- mocks/data.py ■ ■■ invoke ■■■■ ■■ ■■ ■■■■.
- ■■■■ chunk\_id ■ ■■■■ verification.passed ■ False ■ ■■.
- B/C/D ■ NotImplementedError ■ ■■■■ USE MOCK=True ■■■■ ■■ ■■.
- USE MOCK=False ■ ■ import ■■■■ workers.\*.nodes ■ graph.verify ■ ■■■■.

### 7.4 ■■■■ ■■■■ ■■■■ API

day2 agentEx3/Ex4, day3 agentEx5 ■ StateGraph, START, END, add\_node, add\_edge, compile, invoke. MessagesState ■ ToolNode(■■■ ■■) ■ ■■■■ ■■■■ ■■ ■■■■. ■■■■ LLM ■ ■■ ■■ config.get\_chat\_model(role="verify") ■ ■■■■. ■■■■ LLM ■■ ■■ ■■■■.

## 8. B ■■■ ■■■■ — ■■■ / ■■■■ / ■■■

B ■■■ ■■■■ AgentState ■■■■ ■■■■ Chunk ■■■■ ■■■■, ■■■ ■■■■ ■■■ ■, ■■■ request\_id ■■■■ ■■■■ C ■■■ ■■■■. ■■■■ ■■■ ■■■■. ■■■■ ■■■■ ■■■ ■■■■ ■■■■.

### 8.1 ■■■ ■■■

| ■■■                           | ■■■                         | ■■■                                                            |
|-------------------------------|-----------------------------|----------------------------------------------------------------|
| workers/parser/pdf_parser.py  | FileInfo (source_type=pdf)  | ■■■■ ■■■ ■■■ ■■■ Chunk, page_number ■■■                        |
| workers/parser/code_parser.py | FileInfo (source_type=code) | ■■■/■■■/■■■■ ■■■■ Chunk, start_line-end_line                   |
| workers/parser/preprocess.py  | ■■■ FileInfo / Chunk        | title.size_bytes ■■■, ■■■ ■■■■ content                         |
| workers/parser/nodes.py       | AgentState.files            | parse: files+parsed_chunks / retrieve: retrieved_chunks        |
| store/vector_store.py         | request_id + Chunk ■■■■     | upsert ■■■, retrieve ■■ RetrievedChunk (distance, vector_rank) |

### 8.2 ■■■ ■■■

- 1 schemas/files.py ■■■■ FileInfo, Chunk, RetrievedChunk ■■■■ ■■■■. ■■■■ ■■■■ ■■■ ■■■■ ■■■■ ■■■■.
- 2 make\_document\_id / make\_chunk\_id ■ nodes.py ■■■ ■■■■. ■■■■ id ■■■ ■■■■ ■■■ ■■■■ ■■■■.
- 3 pdf\_parser.parse\_pdf: pypdf ■■■ pdfplumber ■■■■ ■■■■ ■■■■. ■■■■ ■■■■ ■■■■ Chunk ■■■■ ■■■■. page\_number ■■■ 1■■■.
- 4 ■■■(TOC) ■■■■ ■■■■ ■■■■ Chunk ■■■■ metadata title ■■■■. ■■■■ ■■■■ ■■■■ ■■■■ ■■■■.
- 5 code\_parser.parse\_code: ast.parse ■■■■ FunctionDef / ClassDef ■■■■ lineno, end\_lineno ■■■■. ■■■■ ■■■■ ■■■■ ■■■■ ■■■■ ■■■■ ■■■■ ■■■■.
- 6 preprocess.extract\_metadata ■■■■ ■■■■, ■■■■ ■■■■, PDF title ■■■■ FileInfo ■■■■. refine\_text ■■■■ ■■■■ ■■■■ ■■■■ ■■■■. ■■■■ ■■■■ ■■■■ ■■■■ ■■■■.
- 7 parse\_files\_node: files ■■■■ pdf/code ■■■■, document\_id ■■■■ parsed\_chunks ■■■■. ■■■■ store.upsert\_chunks(request\_id, chunks) ■■■■.
- 8 store/vector\_store.py: ■■■■ pgvector. initialize ■■■■ ■■■■ ■■■■ ■■■■. ■■■■ request\_id, document\_id, source\_type, page\_number, start\_line, end\_line, content, embedding ■■■■.
- 9 retrieve\_chunks\_node: ■■■■ ■■■■ ■■■■ ■■■■ Chunk ■■■■ ■■■■ ■■■■. ■■■■ request\_id ■■■■. ■■■■ RetrievedChunk ■■■■.
- 10 config.get\_embeddings() ■■■■ ■■■■. ■■■■ gemini-embedding-2, ■■■■ 768. nomic-embed-text ■■■■ 768. bge-m3 ■■■■ 1024 ■■■■ EMBEDDING\_DIMENSION ■■■■ ■■■■ ■■■■.

### 8.3 ■■■ ■■■

- ■■■ PDF ■■■■ .py ■■■■ ■■■■ ■■■■ parsed\_chunks ■■■ 1 ■■■■.
- ■■■■ Chunk ■■■■ chunk\_id, document\_id, source\_type, content ■■■■. PDF ■■■■ page\_number, ■■■■ ■■■■ ■■■■.
- ■■■■ request\_id ■■■■ ■■■■ ■■■■ ■■■■ ■■■■.
- C ■■■■ nodes ■■■■ ■■■■ ■■■■ RetrievedChunk ■■■■ ■■■■ retrieve ■■■■ ■■■■.

### 8.4 ■■■■ ■■■■ ■■■■ API

day1 retrieve\_vector\_documents ■■■■ collection.query(include=documents, metadatas, distances). day3 initialize\_vector\_db, similarity\_search\_with\_score, metadata filter. ■■■■ Chroma PersistentClient ■■■■. ■■■■ ■■■■ VECTOR\_BACKEND=chroma ■■■■ ■■■■ pgvector ■■■■ ■■■■. ■■■■ ■■■■ SQL ■■■■ ■■■■ ■■■■.



| route     | concepts | code_units | flows / tables | cross_references | practice_notes |
|-----------|----------|------------|----------------|------------------|----------------|
| pdf_only  | 1 ■■■    | □          | ■■■■ ■■        | □                | □              |
| code_only | □        | 1 ■■■      | ■■■■ ■■        | □                | □              |
| both      | 1 ■■■    | 1 ■■■      | ■■■■ ■■        | 1 ■■■            | ■■■■ ■■        |

## 9.4 ■■■ ■■■

- MOCK\_RETRIEVED\_CHUNKS ■■■■ AnalysisOutput ■ ■■■■.
- ■■■ ConceptItem / CodeAnalysisItem ■ source\_chunk\_ids ■ 1 ■ ■■■■.
- both ■■■■ cross\_references ■ PDF chunk ■ code chunk ■ ■■■ ■■■■.
- D ■ C ■■■■ import ■■ ■■ AgentState ■ ■ ■■■■ ■■■ ■■■■■ ■■ ■ ■■.

## 9.5 ■■■■ ■■■ ■■■ API

day1 GraphQLQueryPlan.model\_json\_schema ■ model\_validate\_json. day1 build\_fused\_evidence\_context / generate\_answer ■ “■■■ ■■ ■■■ ■■ ■■”. day2 PromptTemplate, ChatGoogleGenerativeAI. Hybrid RAG fusion ■■ ■■■ ■■■■ ■■■. ■■■ B ■ ■■ retrieved\_chunks ■ ■■ ■■■ ■■■■.

## 10. D ■■■ ■■■■ — ■■■ / ■■■■

D ■ C ■■■ ■■■■ retrieved\_chunks ■■■ ■■■ ■■■ 3~5■■■ Obsidian/Notion ■■■ ■■■■ ■■■ ■■■■. ■■■■ ■■■ ■■■■ ■■■■. UI ■■■ ■■■■ quiz\_items ■ final\_markdown ■ key ■■■■.

### 10.1 ■■■ ■■■

| ■■■                           | ■■■ ■                       | ■■■                                |
|-------------------------------|-----------------------------|------------------------------------|
| workers/formatter/quiz.py     | ■■■.■■■ ■■■<br>3~5■■■ + ■■■ | list[QuizItem]                     |
| workers/formatter/markdown.py | YAML + ■■■ + ■■■<br>+ ■■■■  | final_markdown ■■■■                |
| workers/formatter/nodes.py    | ■ ■■■■ ■■■ Graph<br>Node    | quiz_items, final_markdown, status |
| schemas/quiz.py               | ■■■ ■■■■                    | QuizItem                           |

### 10.2 ■■■ ■■■

- 1 schemas/quiz.py ■■■. quiz\_type ■ mcq / short / true\_false. mcq ■ options 4■■■ ■■■■ ■■■. answer ■ "1■■" ■■■■ options ■■■ ■■■■ ■■■ ■■■.
- 2 mocks ■ MOCK\_CONCEPTS, MOCK\_CODE\_UNITS ■■■■ QuizItem ■■■ ■■■■ ■■■■ model\_validate ■■■.
- 3 produce\_quiz\_items: C ■■■■ retrieved\_chunks ■■■■ ■■■ Gemini ■ 3~5■■■ ■■■■. ■■■■ ■■■■ source\_chunk\_ids ■■■■. ■■■■ ■■■■ ■■■■.
- 4 format\_markdown ■■■ ■■■■ ■■■■. YAML → ■■■ → ■■■ ■■■ → ■■■-■■■ ■■■ → Troubleshooting → Quiz. ■■■■ config.EMPTY\_SECTION\_POLICY ■ omit ■■■ ■■■■ ■■■.
- 5 YAML ■: request\_id, route, tags: [studywave, ■■■]. Obsidian ■■■ ■■■ frontmatter ■■■■ ■■■■.
- 6 ■■■ ■■■■ HTML details ■■■ ■■■■ ■■■■ ■■■.■■■■ ■■■■. ■■■■ > [!NOTE], > [!WARNING] ■■■■ ■■■. Streamlit ■■■ ■■■ ■■■■ ■■■■ ■■■ ■■■■ ■■■ ■■■■ ■■■■.
- 7 format\_node ■ quiz ■ markdown ■■■■ dict ■■■■. concepts ■■■■ ■■■■ ■■■■.

### 10.3 ■■■■ ■■■

```

---
request_id: req-demo-001
route: both
tags: [studywave, langgraph]
---

# ■■■ ■■■
...

# ■■■ ■■■ ■■■
...

# ■■■-■■■ ■■■
...

# Troubleshooting

> [!WARNING]
> ■■■ ■■■■ ■■■■ ■■■ ■■■ ■■■■ ■■■■.

# ■■■ ■■■

<details>
<summary>Q1. LangGraph ■■■ ■■■ ■■■■ ■■■■ ■■■■?</summary>

■■■: StateGraph

```

StateGraph Node/Edge compile .  
</details>

## 10.4

- 3 5
- mcq answer options
- final\_markdown --- #
- ui/tabs.py quiz\_items , final\_markdown

## 10.5 API

C Gemini structured output. Pydantic QuizItem schema . ( ) A  
graph/verify.py D

## 11. UI ■■ — 1~2■ ■■

Streamlit. Mock

| ■ ■        | ■ ■                          | ■ ■                                |
|------------|------------------------------|------------------------------------|
| app.py     | streamlit run app.py ■ ■ ■ ■ | ui/app.py ■ main()                 |
| ui/app.py  | ■ ■ ■ ■ ■, ■ ■ ■ ■, ■ ■ ■ ■  | graph.supervisor.run_pipeline      |
| ui/tabs.py | ■ ■ ■ ■                      | concepts / code_units / quiz_items |

████ PDF █████ .py █████. █████ Fileinfo █████ source\_type █████ router █████ route █████. █████  
run\_pipeline █████. █████ st.tabs █████ st.download\_button █████ .md █████.

12. ■■ ■■ ■■

- ```

1 A█ run_graph.py █ Mock █████ ███ █████ ██████.
2 B█ parse_files_node █ ███ █████ █████, supervisor ███ parse █████ █████ ███.
3 C█ mocks █ retrieved_chunks █ analyze_node █ ███ ██████. █████ █████ █████ █████ █████ ██████.
4 D█ mocks █ ███ █████ format_node █ ███ ██████.
5 A█ verify_node █ ███ █████ ██████, █████ █████ ███ █████ █████ ██████.
6 USE MOCK=False █ █████ █ PDF+████ █████ ██████. █ █████ .md █ █████ █████ █████ █████ ██████.

```

13. ■■ ■■■

| ■■                                  | ■■  | ■■ ■ ■■                   |
|-------------------------------------|-----|---------------------------|
| graph/supervisor.py                 | A   | 6■ Node ■ ■ ■■■■■■ ■■■■■■ |
| graph/router.py                     | A   | ■ ■■ ■■ ■■■ ■■■■          |
| graph/verify.py                     | A   | ■■■ ■■■ ■■ ■■■            |
| workers/parser/pdf_parser.py        | B   | page_number ■ ■■ ■■ ■■■   |
| workers/parser/code_parser.py       | B   | ■ ■■■ ■■ ■■ ■■■           |
| workers/parser/preprocess.py        | B   | ■■.■■ ■■■ ■■ ■■■          |
| workers/parser/nodes.py             | B   | ■■■ key ■ ■■■ ■■■         |
| store/vector_store.py               | B■■ | request_id ■■■ ■■■        |
| workers/analysis/prompts.py         | C   | ■■ ■■ ■■ ■■ ■■■ ■■■       |
| workers/analysis/concept.py         | C   | source_chunk_ids ■ ■■■    |
| workers/analysis/code_flow.py       | C   | ■■ ■■■ ■■■ ■■■■■          |
| workers/analysis/cross_reference.py | C   | PDF id ■ ■■ id ■ ■■ ■■■   |
| workers/analysis/practice_notes.py  | C   | ■■ ■■■■ ■■ ■■■■ ■■■■      |
| workers/analysis/nodes.py           | C   | route ■ ■ ■■■ ■■■ ■■■     |
| workers/formatter/quiz.py           | D   | 3~5■■, answer=■■ ■■■■■    |
| workers/formatter/markdown.py       | D   | YAML ■ ■■■ ■■■            |
| workers/formatter/nodes.py          | D   | C■ ■■■■ ■■■ ■■■           |
| ui/app.py / ui/tabs.py              | UI  | ■ ■■ .md ■■■■■ ■■■■       |
| config.py                           | ■■  | .env ■■■■ ■■■ ■■■■        |

|               |  |  |
|---------------|--|--|
|               |  |  |
| mocks/data.py |  |  |

Node PDF python tools/generate\_guide\_pdf.py